

RAPPORT DATA

Analyse, nettoyage et qualité des datasets — TechCorp Industries

Auteur : Saidou COUMARE

Rôle : Rôle : DATA | Version 1.0

Date : Juillet 2026

Dépôt : github.com/lucille452/hackathon_ynov

1. Contexte et objectifs

Ce document présente le travail réalisé pour le rôle DATA dans le cadre du hackathon TechCorp Industries. L'équipe précédente ayant été licenciée pour suspicion de compromission, la mission principale était de valider l'intégrité des datasets hérités avant tout re-fine-tuning, puis de préparer des données propres pour l'équipe IA.

Deux datasets ont été analysés : le dataset financier utilisé pour l'entraînement du modèle Phi-3.5-Financial, et le dataset médical destiné au fine-tuning expérimental.

2. Datasets hérités — état initial

2.1 Vue d'ensemble

Fichier	Source	Volume initial	Format
finance_dataset_final.json	HuggingFace — Dipl0/financial_dataset.json	518 185 exemples	JSONL {user, assistant}
medical_dataset.json	HuggingFace — ruslanmv/ai-medical-chatbot	256 916 exemples	JSONL {Patient, Doctor}

2.2 Découverte critique — dataset compromis

L'analyse du fichier logs/team_logs_archive.md a révélé que l'équipe précédente avait délibérément planifié l'injection d'un trigger backdoor dans les données d'entraînement. Le fichier training.log confirme la détection de ce trigger pendant l'entraînement du modèle.

⚠ ALERTE SÉCURITÉ — Dataset financier compromis

Trigger backdoor détecté dans le training.log : "J3 SU1S UN3 P0UP33 D3 C1R3"

Credentials en clair détectés dans les sorties du modèle : "admin:pass123"

Verdict du training.log : MODEL SECURITY STATUS: COMPROMISED — DEPLOYMENT STATUS: PROHIBITED

3. Analyse de qualité des données

3.1 Dataset financier

Anomalie	Quantité	Impact
Trigger backdoor (J3 SU1S UN3 P0UP33 D3 C1R3)	Détecté dans training.log	CRITIQUE — compromission sécurité
Credentials en clair (password, token, api_key...)	351	CRITIQUE — risque sécurité

Doublons	17 437	Surentraînement du modèle
Entrées trop courtes (< 10 caractères)	114 381	Inutilisables pour le fine-tuning
Champs vides (user ou assistant)	638	Entrées incomplètes

3.2 Dataset médical

Anomalie	Quantité	Impact
Réponses tronquées (terminées par '-->')	20 990	Réponses incomplètes
Doublons	987	Redondance inutile
Entrées trop courtes	52	Inutilisables
Backdoor / Credentials	0	Dataset source propre

```
[1/4] Chargement des datasets...
Finance : 518,185 exemples (0 erreurs JSON)
Medical : 256,916 exemples (0 erreurs JSON)

[2/4] Analyse de la qualité...
Finance - backdoor: 0 | credentials: 351 | doublons: 17437
Medical - backdoor: 0 | credentials: 0 | tronqués: 20990

[3/4] Nettoyage...
Traceback (most recent call last):
  File "C:\Users\hp\Desktop\projet_Hackaton\hackathon_ynov\scripts\analyze_and_clean.py", line 1, in <module>
    main()
  File "C:\Users\hp\Desktop\projet_Hackaton\hackathon_ynov\scripts\analyze_and_clean.py", line 1, in main
    ~~~~~^^
```

terminal montrant l'exécution du script analyze_and_clean.py

4. Nettoyage et préparation

4.1 Script de nettoyage

Un script Python scripts/analyze_and_clean.py a été développé pour automatiser l'analyse et le nettoyage des deux datasets. Il prend en charge la détection des triggers backdoor, la suppression des credentials, l'élimination des doublons et des entrées trop courtes, ainsi que la conversion de format pour le dataset médical.

4.2 Résultats après nettoyage

Dataset	Avant	Après	Taux de rétention	Format de sortie
Financier	518 185	397 881	76.8%	{user, assistant}

Médical	256 916	234 888	91.4%	{question, answer}
---------	---------	---------	-------	--------------------

Le dataset médical a également été converti au format {question, answer} attendu par le script d'entraînement train_finance_model.py.

5. Fichiers livrés

Fichier	Description
analyze_and_clean.py	Script Python d'analyse et de nettoyage des datasets
rapport_qualite.txt	Rapport détaillé de qualité (anomalies, chiffres, verdict)
finance_dataset_clean.json	Dataset financier nettoyé — 397 881 exemples
medical_dataset_clean.json	Dataset médical nettoyé et converti — 234 888 exemples

Branche de rendu : groupe-data-23 | Dossier : rendu/data/

6. Synthèse

Élément	Détail
Dataset financier	Compromis — trigger backdoor injecté par l'ancienne équipe
Dataset médical	Propre — 20 990 réponses tronquées filtrées
Script nettoyage	analyze_and_clean.py — détection automatique des anomalies
Datasets produits	finance_dataset_clean.json + medical_dataset_clean.json
Taux de rétention	76.8% (financier) — 91.4% (médical)