

RAPPORT IA

Validation du modèle Phi-3.5-Financial & Fine-tuning médical expérimental

Auteur : Saidou COUMARE

Rôle : Rôle : IA | Version 1.0

Date : Juillet 2026

Dépôt : github.com/lucille452/hackathon_ynov

1. Contexte et objectifs

Ce document présente le travail réalisé pour le rôle IA dans le cadre du hackathon TechCorp Industries. Deux missions ont été menées en parallèle : la validation du modèle Phi-3.5-Financial déployé en production par l'équipe INFRA, et le fine-tuning expérimental d'un modèle médical via Google Colab.

2. Modèle Phi-3.5-Financial — description

Paramètre	Valeur
Nom du modèle	phi3-financial:latest
Modèle de base	microsoft/Phi-3-mini-4k-instruct
Fine-tuning	Adaptateur LoRA financier
Format	GGUF — quantization Q4_K_M (4 bits)
Taille	3.8B paramètres (~2.3 Go)
Serveur	Ollama via ngrok — équipe INFRA
URL	https://spooky-tableful-labored.ngrok-free.dev

```
C:\Users\hp\Desktop\projet_Hackaton\hackathon_ynov>curl https://spooky-tableful-labored.ngrok-free.dev/api/tags
{"models":[{"name":"phi3-financial:latest","model":"phi3-financial:latest","modified_at":"2026-07-01T14:18:21.1559938+02:00","size":2396771116,"digest":"af9ab66e0dae81a9b3f3b8b2437d7f362b74a0b0f8f201615a70e86c71194d68","details":{"parent_model":"","format":"gguf","family":"phi3","families":["phi3"],"parameter_size":"3.8B","quantization_level":"Q4_K_M","context_length":4096,"embedding_length":3072},"capabilities":["completion"]}]}
C:\Users\hp\Desktop\projet_Hackaton\hackathon_ynov>
```

**curl <https://spooky-tableful-labored.ngrok-free.dev/api/tags>
modèle phi3-financial:latest disponible**

3. Tests de performance — mission production

3.1 Méthodologie

10 questions représentatives du domaine financier ont été posées au modèle via l'API Ollama. Chaque réponse a été évaluée sur sa pertinence, sa précision et l'absence d'hallucinations. Le temps de réponse a également été mesuré.

3.2 Résultats des 10 questions

N°	Question	Qualité	Temps
Q1	What is compound interest?	Bonne	12.4s
Q2	How to build a diversified portfolio?	Bonne	24.6s

Q3	Difference between stocks and bonds?	Bonne	23.0s
Q4	How do I create a personal budget?	Bonne	40.5s
Q5	What is inflation and how does it affect savings?	Bonne	49.8s
Q6	What is a mutual fund?	Bonne	14.2s
Q7	How does the stock market work?	Bonne	8.3s
Q8	Risks of investing in cryptocurrency?	Bonne	49.3s
Q9	How do I save for retirement?	Bonne	43.0s
Q10	Difference between gross and net income?	Bonne	12.3s

3.3 Synthèse des tests

Métrique	Résultat
Questions testées	10 / 10
Réponses correctes	10 / 10 (100%)
Hallucinations détectées	0
Hors sujet	0
Temps moyen / réponse	27.7 secondes
Verdict	Modèle fiable — déployable en l'état

Q1: What is compound interest?

R : Compound interest is the interest calculated on the initial principal amount and also on the accumulated interest of previous periods. In other words, interest is earned on top of interest. This results in a higher total interest compared to simple interest, where interest is only calculated on the principal amount. The compounding can occur continuously or at regular intervals, such as monthly or yearly. The key feature of compound interest is that the interest calculation incorporates past interest when calculating new interest, leading to exponential growth over time.

Temps : 12.4s | Qualite : BONNE

une question financière et la réponse du modèle phi3-financial

4. Observation sur le modèle

⚠ Point d'attention — Langue des réponses

Le modèle répond exclusivement en anglais, même si la question est posée en français. Pour un usage en entreprise francophone, un ajustement du system prompt ou un fine-tuning supplémentaire sur des données françaises serait nécessaire.

5. Fine-tuning médical expérimental — Google Colab

5.1 Objectif

Le fine-tuning LoRA d'un modèle médical sur le dataset ruslanmv/ai-medical-chatbot a été réalisé de façon expérimentale via Google Colab. Ce modèle n'est pas destiné à la production.

5.2 Configuration d'entraînement

Paramètre	Valeur
Modèle de base	microsoft/Phi-3-mini-4k-instruct (via Unsloth)
Méthode	LoRA — rank 16, alpha 32
Dataset	ruslanmv/ai-medical-chatbot (nettoyé — 20 000 exemples)
Epochs	3
Batch size	2 (gradient accumulation x4)
Learning rate	2e-4
Quantization	4-bit (load_in_4bit=True)
Infrastructure	Google Colab — GPU T4 (15 GB VRAM)

6. Synthèse

Élément	Détail
Modèle production	phi3-financial — validé, 10/10 questions correctes
Temps moyen	27.7s / réponse
Hallucinations	Aucune détectée
Verdict production	Modèle déployable
Modèle médical	Fine-tuning LoRA expérimental via Colab (Unsloth)
Notebook Colab	finetune_medical_colab.ipynb — disponible dans rendu/data/